

Bilan de Clôture — Mois 2

E-Commerce Sales Analysis · UCI Online Retail Dataset

Simulation consultant TATA / Forage · Data Analyst Career Transition · 2026

Dataset	UCI Online Retail — 541 909 transactions, marché UK e-commerce, cadeaux & décoration
Rôle simulé	Consultant Data — boutique fictive non technique
Livrables	5 notebooks · base PostgreSQL · 29 requêtes SQL · présentation 11 slides Google Slides
Statut	✅ Clôturé dans son essence — Juin 2026

1. Contexte et mission

Le projet de mois 2 s'est inscrit dans une simulation de mission consultant : un mandat réel, un interlocuteur fictif non technique, des questions business précises à résoudre, et des livrables défendables en entretien.

La boutique fictive — positionnée sur le marché UK des cadeaux et de la décoration — souhaitait comprendre deux choses : quels sont les facteurs qui portent la croissance de son chiffre d'affaires, et quelle stratégie mettre en place pour l'année suivante. Trois questions business ont structuré l'ensemble du travail.

Q1	Quels produits et périodes génèrent le plus de revenus ?
Q2	Qui sont les clients les plus actifs, et d'où viennent-ils ?
Q3	Quelles tendances temporelles structurent l'activité de la boutique ?

2. Ce qui a été produit

2.1 Notebooks Jupyter

Notebook	Phase	Contenu
00_Reconnaissance	Cadrage métier	Dictionnaire des variables, 3 questions business, KPIs, limites structurelles, hypothèses initiales
01_Exploration	EDA	Structure du dataset, types, anomalies détectées, dispersion, déséquilibre géographique
02_Nettoyage	Data Cleaning	Suppression doublons, isolation hors-produit, conservation Unknown, création TotalPrice, parsing dates
03_Analyse	Data Analysis	Métriques par dimension (produits, clients/géo, temporel), constats documentés, synthèse business
04_Visualisation	Dataviz	9 figures Matplotlib sur 4 dimensions, GridSpec pour figures composites, markdown analytique post-graphe
05_Conclusions	Recommandations	Contexte mission, réponses aux 3 questions, 5 recommandations priorisées, limites, conclusion ouverte

2.2 Base de données PostgreSQL

Le dataset nettoyé a été importé dans une base PostgreSQL locale (DBeaver), table `online_retail` — 532 663 lignes après nettoyage. Deux vues ont été créées : `vrais_produits` (hors descriptions hors-produit) et `ventes_reeles` (hors annulations).

Un document de reproductibilité SQL en 29 requêtes couvre l'intégralité de l'analyse Pandas : métriques globales, top produits avec taux d'annulation, segmentation client, analyse géographique, temporelle, et questions de synthèse avec CTEs et fenêtres analytiques. Objectif : prouver que chaque résultat Pandas est vérifiable par une voie indépendante.

2.3 Présentation business — 11 slides

#	Slide	Message clé
1	Titre	E-Sales Boutique — Analyse de croissance du CA
2	Synthèse	Quatre facteurs portent le CA
3	Recommandations	5 actions priorisées
4a	Produits — CA & annulations	Le REGENCY CAKESTAND domine — signal d'alerte sur l'annulation
4b	Produits — CA vs dépense moyenne	Les produits peu coûteux assurent le top CA
5a	Clients — Unknown vs identifiés	Le meilleur segment est le plus invisible

5b	Clients — Unknown par pays	Signal géographique concentré : Hong Kong à 100%
6	Géographie	84,7% UK — aucun marché de sécurité en cas de turbulences
7	Temporel	Sept–Nov : saison. Janv–Avr : zone de risque
8	Limites	Ce que les données ne permettent pas de conclure
9	Conclusion	La décision stratégique centrale est géographique

3. Résultats par dimension

3.1 Produits

Cadre appliqué sur chaque constat : Constat → Comportement détecté → Risque ou opportunité → Action recommandée.



Produit phare — signal ambigu

REGENCY CAKESTAND 3 TIER : 164 459 £ de CA, premier produit du catalogue. Taux d'annulation le plus élevé parmi les 20 premiers : 8,22%. La rentabilité repose sur le volume de commandes — pas sur la valeur unitaire. Sans investigation sur la cause des annulations, le risque reste non géré.



Opportunité non exploitée

PICNIC BASKET WICKER 60 PIECES : 649 £ / unité, zéro annulation, deux transactions seulement. Profil d'achat atypique — une unité test suivie de 60 unités. Compatible revendeur. Le potentiel CA est réel si le profil client est confirmé côté boutique.

Enseignement transversal : c'est la fréquence d'achat qui construit le CA, pas la valeur unitaire. Aucun produit individuel n'atteint 2% du CA global.

3.2 Clients & Géographie

Constat	Risque / Opportunité	Action recommandée
Clients Unknown = 1er segment par CA et volume	Opportunité — taux d'annulation 0,12% : segment le plus fiable	Création de compte obligatoire à l'achat
Hong Kong : 100% du CA local généré par des Unknown	1 seule personne, 276 transactions (source : SQL)	Investigation prioritaire avant décision sur ce marché
UK : 84,7% du CA global	Risque de concentration — aucun marché secondaire en cas de turbulences	Définir une intention : consolidation UK ou diversification ?
USA : 38,62% d'annulations, rang 30	Anomalie sur faible volume (7 commandes)	Exclure sans investigation préalable

3.3 Temporel

- Septembre, octobre, novembre : CA supérieur à 1 million de livres chacun — période la plus lucrative.
- Avril : point bas annuel.
- Décembres exclus : 2010 tronqué à 23 jours, 2011 à 8 jours — pic réel de fin d'année non mesurable.
- Jeudi : jour le plus actif (4 302 ventes). Dimanche : volume deux fois plus faible.

- Ratio transactions / commandes stable à ~20 lignes par facture toute l'année.

 Limite critique

Une seule année de données (2011). Il est impossible de qualifier la saisonnalité comme récurrente ou structurelle. Les termes « saisonnalité » et « anticipation » ont été délibérément évités dans tous les livrables.

4. Compétences acquises

4.1 Compétences techniques

Outil / Technique	Usage dans le projet	Niveau observé
Pandas — groupby + agg()	Métriques multi-dimensions, segmentation client/produit/pays	Solide
Pandas — lambda dans agg()	Calcul taux d'annulation via str.startswith('C')	En progression
Matplotlib — GridSpec	Figures composites multi-graphes	Acquis
Matplotlib — plt.subplots()	Graphes standalone sur dimensions temporelles	Acquis
PostgreSQL / DBeaver	29 requêtes SQL reproduisant l'analyse Pandas	En progression
CTEs et fenêtres analytiques	Reproductibilité SQL — questions de synthèse	En construction
Git — conventional commits	feat., fix., docs., refactor., chore: — workflow complet	Acquis
copy(deep=True)	Prévention SettingWithCopyWarning sur DataFrames dérivés	Acquis

4.2 Compétences analytiques

Cadre analytique établi

Le framework Constat → Comportement détecté → Risque ou opportunité → Action recommandée a été appliqué de manière cohérente sur les quatre dimensions. Ce n'était pas un réflexe au départ — c'est devenu une discipline au fil du projet.

Séparation stricte des phases

Phase 3 : constats et anomalies uniquement. Phase 5 : interprétation et recommandations. Cette frontière a été tenue rigoureusement, y compris sous pression de reformulation — plusieurs tentatives d'interprétation prématurée ont été identifiées et corrigées en cours de projet.

Précision métrique

La distinction entre nb_transactions (.count()), nb_commandes (.nunique() sur InvoiceNo), dépense moyenne (AVG par ligne) et panier moyen (SUM par InvoiceNo puis AVG) est maintenant ancrée. Ces distinctions sont sources d'erreurs classiques en entretien technique.

Discipline de non-interprétation

Plusieurs sur-interprétations ont été identifiées et rejetées : saisonnalité structurelle (une seule année de données), anticipation des achats de Noël (comportement non prouvé), clientèle professionnelle (label non vérifié dans les données). Règle appliquée : on ne formule pas ce qu'on ne peut pas prouver.

4.3 Compétences de communication

- Structure pyramide de Minto (SCR) appliquée aux livrables écrits et à la présentation.
- Titres de slides formulés comme des affirmations, pas des thèmes.
- Séparation oral / écrit : ce que le graphe ne montre pas explicitement passe à l'oral, pas sur la slide.
- Reformulation des constats en langage client non technique — sans jargon, chiffres contextualisés.
- Limites documentées et présentées comme gage de crédibilité analytique, pas comme des excuses.

5. Points de vigilance à consolider

Point de vigilance	Contexte d'apparition	Objectif mois 3
reset_index() après groupby	Oublié systématiquement après les agrégations — corrigé à chaque fois	Réflexe automatique dès le premier groupby
Fluidité SQL	Requêtes correctes mais construites pas à pas — hésitations sur la structure CTE	Écrire une CTE multi-niveaux sans référence sur le projet finance/fraude
Syntaxe Matplotlib	Ordre des appels (fig, ax, plt.show()) source de friction en phase 4	Stabiliser le pattern fig/ax avant d'introduire Power BI
Variables DataFrame nommées	Bonne discipline maintenue — ne pas chaîner	Maintenir cette approche sur tous les projets suivants

6. Bilan consultant — mission accomplie ?

Ce qui a été fait au niveau consultant

- Les questions business ont été posées avant le code — à chaque dimension, à chaque étape.
- Les décisions analytiques ont été documentées avec leur justification (conservation des Unknown, isolation des hors-produit, exclusion des décembres tronqués).
- Des signaux non évidents ont été identifiés : profil revendeur du PICNIC BASKET sur 2 transactions, concentration des Unknown à Hong Kong, anomalie USA sur 7 commandes seulement.
- La sur-interprétation a été évitée — plusieurs fois, délibérément, avec correction en cours de route.
- Les limites ont été présentées avant qu'un interlocuteur puisse les soulever — c'est de la rigueur, pas de la modestie.

La nuance honnête

Un consultant data en mission réelle aurait eu accès à des données supplémentaires : catégories clients, données d'acquisition, historique multi-années, retours qualitatifs de la boutique. Ici, le travail a été conduit avec ce que le dataset permettait — et les limites ont été documentées honnêtement plutôt que contournées. C'est exactement ce qu'on attend d'un analyste junior sérieux.

Verdict

Mission accomplie dans le périmètre défini. Le mandat était d'identifier les facteurs de croissance du CA et de formuler une stratégie pour l'année suivante. Les quatre facteurs ont été identifiés, les cinq recommandations sont actionnables, les limites sont documentées. La présentation est défendable face à un propriétaire non technique comme face à un recruteur.

7. Ce qui reste à finaliser

7.1 Commits en attente

- fix: corrections markdown sur 05_Conclusions.ipynb
- feat: commit du notebook 05_Conclusions.ipynb finalisé
- docs: mise à jour feuille de route GitHub — ancienne version supprimée, nouvelle uploadée
- docs: bilan de mi-parcours mis à jour — références phase 5 supprimées

7.2 README à refactoriser

Le README actuel reflète la logique technique du projet. Il doit être entièrement réécrit avec un angle 60% business / 40% technique — la problématique client d'abord, les résultats ensuite, le stack technique en dernier. C'est ce qu'un recruteur verra en premier sur le dépôt GitHub.

8. Ce qui s'ouvre — Mois 3

Le mois 3 bascule vers un domaine où les anomalies analytiques ont une signification métier directe : la finance et la détection de fraude.

Élément	Détail
Domaine	Finance & Détection de fraude
Stack	Python + Pandas + BigQuery(nouveau) + SQL (consolidation) + Power BI (nouveau)
Power BI	Dashboards interactifs — couche de restitution que Matplotlib ne couvrait pas
Socle mois 2	Rigueur analytique : question d'abord, preuve ensuite, limite documentée
Horizon candidatures	Environ 1 mois : le mois 3 doit produire un livrable à forte visibilité portfolio