

BILAN DE MI-PARCOURS

Projet d'analyse — E-Commerce Sales Dataset

Mai 2026

Contexte	Simulation TATA / Forage (Kaggle)
Dataset	Online Retail — 541 909 transactions
Rôle	Consultant Data — Boutique en ligne
Avancement	3 / 6 phases terminées (50 %)

1. Vue d'ensemble du projet

Ce projet s'articule en 6 phases distinctes. Le présent document fait le bilan des 3 premières phases complétées et cadre les 3 phases à venir.

00	Reconnaissance & Cadrage métier ✓ TERMINÉE
01	Exploration des données (Data Exploration) ✓ TERMINÉE
02	Nettoyage des données (Data Cleaning) ✓ TERMINÉE
03	Analyse (Data Analysis) ✓ TERMINÉE
04	Visualisation (Matplotlib / Seaborn) ☉ À VENIR
05	Intégration IA — Synthèse automatique des KPIs ☉ À VENIR
06	Conclusion & Recommandations + Support de présentation ☉ À VENIR

2. Phases terminées — Synthèse

Phase 0 — Reconnaissance & Cadrage métier

Objectif : Poser le cadre métier avant tout travail technique sur le dataset.

Livrable

- Dictionnaire complet des 8 colonnes et leur utilité analytique
- 3 questions business définies : revenus, comportement client, tendances & anomalies
- KPIs identifiés : CA total/pays/produit, fréquence d'achat, valeur moyenne par commande, taux de retours
- Limites documentées : absence de catégories produits, CustomerID à 25% de NaN, aucune métrique marketing
- Hypothèses initiales formulées avant toute exploration des données

Points clés

- Boutique UK-centrique (monnaie : livres sterling) — impact sur toute l'analyse géographique
- Dataset de simulation TATA/Forage — fiabilité correcte mais limites structurelles connues
- Problématique centrale : identifier les moteurs de croissance du CA et élaborer une stratégie pour l'année suivante

Phases 1 & 2 — Exploration & Nettoyage

Objectif : Comprendre la structure du dataset et le rendre fiable pour l'analyse.

Exploration — principaux constats

Constat	Détail
Taille initiale	541 909 lignes × 8 colonnes
Doublons détectés	5 268 lignes entièrement dupliquées
CustomerID	~25% de valeurs manquantes (float incohérent pour un ID)
Description	NaN + valeurs aberrantes non-produits
Dispersion forte	Quantity std 218 pour moyenne 9.55 / UnitPrice std 96.75 pour moyenne 4.6£
Déséquilibre géo.	United Kingdom représente ~91% des transactions
Incohérence clé	4 070 StockCodes uniques vs 4 223 Descriptions uniques

Nettoyage — décisions prises

- Suppression des 5 268 doublons (`drop_duplicates()`)
- Description : filtre par pattern (majuscules, chiffre+maj, 'Manual') + liste noire de 8 valeurs aberrantes
- CustomerID : NaN convertis en 'Unknown' via `fillna()` — conservés car ils représentent 25% du dataset avec des transactions valides
- Création de `TotalPrice` = `Quantity` x `UnitPrice` (arrondi à 2 décimales)
- InvoiceDate converti en datetime — extraction des colonnes year, month, day
- 401 lignes à `UnitPrice` = 0 conservées sans filtre explicite — neutres par construction (`TotalPrice` = 0)

Taille finale du dataset propre : ~536 000 lignes | Aucune valeur manquante résiduelle hormis les 'Unknown' documentés

Phase 3 — Analyse

Objectif : Répondre aux 3 questions business avec des métriques structurées par dimension.

Dimension Produits

Métrique	Résultat clé
Produit le plus lucratif	REGENCY CAKESTAND 3 TIER — 164 459 £ de CA
Produit le plus commandé	WHITE HANGING HEART T-LIGHT HOLDER — 2 302 commandes
Plus forte dépense moyenne	PICNIC BASKET WICKER 60 PIECES — 19 809 £ / commande (volume très faible)
Taux annulation le plus élevé	REGENCY CAKESTAND 3 TIER — 8.22% parmi les produits lucratifs
Descriptions hors-produit isolées	POSTAGE, DOTCOM POSTAGE, AMAZON FEE, Manual, SAMPLES

Dimension Clients & Géographie

Dimension	Constat principal
CA par pays	UK — 84.7% du CA global Netherlands 2e avec 8M£ d'écart
Taux annulation USA	38.62% — anomalie majeure sur 7 commandes seulement
Segment 'Unknown'	Clients anonymes = 1er segment par CA et volume de commandes
Taux annulation Unknown	0.12% — segment très fiable malgré l'anonymat
Hong Kong	100% des clients sont Unknown — flux totalement anonyme
Pays 'Unspecified'	44.72% du CA provient de clients Unknown — double incertitude

Dimension Temporelle

Période	Constat
Données exploitées	Janvier à Novembre 2011 (décembres tronqués exclus)
Mois les plus lucratifs	Septembre, Octobre, Novembre — CA > 1M£ chacun
Mois le plus faible	Avril 2011 — CA le plus bas de l'année
Ratio transactions/commandes	~20 lignes produit par commande — stable toute l'année
Jour le plus actif	Jeudi — 4 302 ventes
Jour le moins actif	Dimanche — 2 126 ventes (moitié du jeudi)

Vérification des hypothèses initiales (Phase 0)

Hypothèse	Verdict	Nuance
UK = pays avec le plus de transactions	VALIDÉE	UK représente 84.7% du CA et domine toutes les métriques
Fin d'année = périodes les plus lucratives	VALIDÉE	Sept–Nov concentrent les pics > 1M£
Taux d'annulation global faible	NUANCÉE	Globalement faible, mais USA 38.62%, REGENCY 8.22%, client 15769 11.56%

3. Anomalies & points de vigilance

#	Anomalie	Impact sur l'analyse
1	Décembre 2010 (23 jours) et Décembre 2011 (8 jours) tronqués	Exclus de la comparaison mensuelle — CA de décembre biaisé
2	Descriptions hors-produit (POSTAGE, AMAZON FEE, etc.)	Isolées manuellement — non scalable sans catégorisation dans le dataset
3	Clients 'Unknown' (25% du dataset)	Segment le plus lucratif mais sans profil exploitable — zone d'ombre stratégique
4	Pays 'Unspecified' + Clients 'Unknown'	Double incertitude : 44.72% du CA de ce pays est non tracé
5	USA — taux d'annulation 38.62% sur 7 commandes	Anomalie statistique sur volume trop faible pour conclure
6	401 lignes à UnitPrice = 0	Jamais filtrées — TotalPrice = 0 par construction, aucun impact sur les calculs de CA

4. Phases à venir

Phase 4 — Visualisation

Objectif : Rendre les résultats clairs et lisibles. Matplotlib et Seaborn suffisent pour ce projet Mois 2.

Visualisations prévues :

- Bar chart horizontal — Top 20 produits par CA
- Line chart — Évolution mensuelle du CA (janv–nov 2011)
- Bar chart — CA par pays (top 10, UK exclu pour lisibilité)
- Bar chart — Commandes par jour de la semaine
- Scatter plot — Relation CA vs Nb commandes par client (profils outliers)
- Heatmap — Corrélations entre métriques numériques

Note : Power BI (dashboards interactifs) est prévu en Mois 3 — Streamlit (mini-app) en Mois 4.

Phase 5 — Intégration IA

Objectif : Utiliser l'IA pour synthétiser automatiquement les KPIs et insights — périmètre réduit Mois 2.

-  L'IA intervient après l'analyse — uniquement pour produire un résumé automatique des KPIs et insights clés
-  L'IA ne nettoie pas les données — cette étape a été réalisée manuellement en Phase 1
-  L'IA n'analyse pas à la place — les constats métier sont issus du travail analytique des Phases 1 à 4
- Résultat attendu : un texte synthétique généré à partir des outputs de l'analyse, intégré au rapport final

Phase 6 — Conclusion & Recommandations

Objectif : Transformer l'analyse en valeur business — rapport final et support de présentation.

Contenu prévu

- Résumé clair des résultats par dimension (produits, clients, géographie, temporel)
- Réponses directes aux 3 problématiques business posées en Phase 0
- Recommandations actionnables formulées à destination de la boutique (rôle : consultant data)
- Limites du projet et pistes d'amélioration documentées

Format de restitution

- Storytelling fluide : séparation graphiques / texte narratif
- Support de présentation incluant les visualisations les plus pertinentes
- Rapport final structuré avec réponses aux demandes initiales de la boutique

5. Bilan de compétences — Mi-parcours

Compétences techniques mobilisées

Outil / Technique	Usage dans le projet	Niveau observé
Pandas	Exploration, nettoyage, agrégations, groupby, filtres	Solide
Python / Pathlib	Renommage de fichiers, gestion de chemins	Acquis
pd.to_datetime()	Parsing de dates, extraction year/month/day	Acquis
Filtres conditionnels	Nettoyage Description, isolation Unknown/hors-produit	Solide
copy(deep=True)	Prévention des SettingWithCopyWarning	Acquis
groupby + agg()	Métriques multi-dimensions (produit, client, pays, temps)	Solide
lambda dans agg()	Calcul taux annulation (str.startswith('C'))	En progression

Points forts identifiés

- Approche analytique rigoureuse : question business d'abord, code ensuite
- Qualité de la documentation des décisions (constats rédigés dans les notebooks)
- Gestion des cas limites : conservation des 'Unknown', isolation des hors-produit plutôt que suppression
- Capacité à nuancer les résultats (ex : hypothèse annulation nuancée, pas binaire)

Points de progression identifiés

- reset_index() : réflexe à consolider après les groupby
- Automatisation SQL : fluidité à renforcer
- Matplotlib / Seaborn : syntaxe et ordre des appels (objet principal de la Phase 4)

Ce projet de mi-parcours valide la capacité à mener une analyse de bout en bout sur un dataset réel : cadrage métier structuré, nettoyage rigoureux, analyse multi-dimensionnelle documentée. Les 3 phases restantes (visualisation, dashboard, recommandations) constituent le passage de l'analyse à la restitution — compétence clé du data analyst.