

REPRODUCTIBILITÉ SQL

E-Commerce Sales Analysis — Phase 3

Mois 2 — Data	Base de données	data_month2	Projet Analyst
	Table	online_retail	
	Outil	PostgreSQL / DBEaver	
	Dataset	online_retail_clean.csv (déjà nettoyé)	

Contexte & Règles du jeu

Ce document reproduit en SQL l'intégralité de l'analyse menée en Pandas lors de la Phase 3. Pour chaque dimension analysée (Produits, Clients & Géographie, Temporel), une série de questions est posée. L'objectif est d'écrire les requêtes SQL correspondantes dans DBeaver.

Ce que tu dois savoir sur le dataset

- Les annulations sont identifiées par un InvoiceNo commençant par la lettre 'C'
- Les descriptions hors-produit à exclure : 'DOTCOM POSTAGE', 'POSTAGE', 'SAMPLES', 'Manual', 'AMAZON FEE'
- Les clients anonymes ont la valeur 'Unknown' dans la colonne CustomerID
- $\text{TotalPrice} = \text{Quantity} \times \text{UnitPrice}$ — cette colonne est déjà présente dans le dataset nettoyé
- Les colonnes temporelles disponibles : InvoiceDate (timestamp), year, month, day (entiers)

Rappel des métriques calculées en Pandas

Métrique	Pandas	Équivalent SQL (à trouver)
CA total	sum('TotalPrice')	SUM(total_price)
Nb transactions	count('InvoiceNo')	COUNT(invoice_no)
Nb commandes distinctes	nunique('InvoiceNo')	COUNT(DISTINCT invoice_no)
Dépense moyenne par ligne	mean('TotalPrice')	AVG(total_price)
Taux d'annulation (%)	lambda x: x.str.startswith('C')	LIKE 'C%' + ratio
Valeur moyenne par commande	groupby InvoiceNo → sum → mean	Sous-requête ou CTE

1. Dimension Produits

Reproduire l'analyse de la colonne Description — hors-produit exclus

1.1 Métriques globales

01

Quel est le chiffre d'affaires global de la boutique, toutes transactions confondues ?

💡 Penser à exclure les descriptions hors-produit avant d'agréger.

02

Quelle est la valeur moyenne par commande — c'est-à-dire, combien dépense un client en total sur une seule facture ?

💡 Une facture = un InvoiceNo. Il faut d'abord sommer le TotalPrice par facture, puis faire la moyenne. Les factures annulées (InvoiceNo commençant par 'C') doivent être exclues.

1.2 Top produits

03

Quels sont les 20 produits qui génèrent le plus de chiffre d'affaires ? Afficher aussi leur nombre de transactions, leur nombre de commandes distinctes, leur dépense moyenne et leur taux d'annulation.

💡 Reproduire le tableau récapitulatif complet de la Phase 3.

04

Quel est le produit le plus commandé (le plus de commandes distinctes) ?

05

Quel est le produit avec la plus forte dépense moyenne par ligne de commande ?

💡 Attention : la dépense moyenne inclut les lignes annulées. Croiser avec le taux d'annulation.

1.3 Annulations

06

Pour chaque description hors-produit (POSTAGE, AMAZON FEE, SAMPLES, Manual, DOTCOM POSTAGE), combien de lignes existent dans la table, et combien sont des annulations ?

💡 C'est la vérification qui avait justifié leur isolation plutôt que leur suppression.

07

Quels sont les produits avec le taux d'annulation le plus élevé, parmi ceux qui ont au minimum 10 transactions ?

💡 *Le filtre sur 10 transactions permet d'écarter les taux artificiellement élevés sur 1 ou 2 lignes.*

2. Dimension Clients & Géographie

Reproduire l'analyse par CustomerID et Country — descriptions hors-produit exclus

2.1 Géographie — par pays

08

Quels sont les 30 pays classés par chiffre d'affaires décroissant ? Afficher aussi le nombre de commandes distinctes, le nombre de transactions, et le taux d'annulation par pays.

09

Quelle est la part du Royaume-Uni dans le CA global (en pourcentage) ?

💡 Utiliser une sous-requête ou un CTE pour calculer le CA total, puis diviser le CA UK par ce total.

10

Quel pays a le taux d'annulation le plus élevé ? Combien de commandes distinctes ce pays a-t-il passé au total ?

💡 Ne pas filtrer sur un nombre minimum de commandes — l'anomalie doit apparaître telle quelle.

2.2 Clients

11

Quels sont les 20 clients classés par chiffre d'affaires décroissant ? Afficher le CA, le nombre de commandes et le taux d'annulation.

12

Quel segment de clients génère le plus de CA et passe le plus de commandes ?

💡 La réponse est dans les données — ne pas présupposer.

2.3 Investigation sur les clients Unknown

En Pandas, une investigation spécifique avait été menée sur les clients dont le CustomerID vaut 'Unknown'.

Les questions suivantes reproduisent ce panorama par pays.

13

Pour chaque pays, combien de CA, de commandes distinctes, de transactions et de produits distincts sont générés par les clients Unknown ?

14

Pour chaque pays, quelle est la part du CA des Unknown dans le CA total de ce pays (en pourcentage) ?

 *Utiliser un CTE ou une sous-requête pour calculer le CA total par pays, puis jointure.*

15

Quel pays a 100% de ses clients dans le segment Unknown ?

16

Pour le pays dont tous les clients sont Unknown : vérifier en listant toutes ses transactions.

3. Dimension Temporelle

Reproduire l'analyse par période — décembres 2010 et 2011 exclus

Rappel : décembre 2010 (23 jours) et décembre 2011 (8 jours) sont tronqués. Ils doivent être exclus de toutes les analyses mensuelles pour éviter un biais de comparaison.
La période d'analyse valide est donc : janvier 2011 → novembre 2011.

3.1 Vérification des périodes

17

Pour les mois de décembre 2010 et décembre 2011 : quelle est la date de début et de fin des transactions, et combien de jours distincts sont couverts ?

💡 C'est la requête qui justifie leur exclusion de l'analyse mensuelle.

3.2 Analyse mensuelle (janv–nov 2011)

18

Pour chaque mois de janvier à novembre 2011, calculer le CA total, le nombre de commandes distinctes et le nombre de transactions. Trier par CA décroissant.

19

Quels sont les 3 mois les plus lucratifs ? Quel est leur CA ?

20

Pour chaque mois, calculer le ratio moyen de transactions par commande.

💡 $\text{Ratio} = \text{nb_transactions} / \text{nb_commandes}$. Ce ratio doit être stable autour de 20 peu importe le mois.

3.3 Analyse par jour de la semaine

21

Pour chaque jour de la semaine, combien de commandes distinctes ont été passées ? Trier par volume décroissant.

💡 La colonne 'day' contient un entier. Utiliser CASE WHEN ou TO_CHAR selon la représentation dans ta table.

22

Quel est l'écart en nombre de commandes entre le jour le plus actif et le jour le moins actif ?

4. Questions de synthèse

Reproduire les réponses aux 3 problématiques business en SQL

4.1 Analyse des revenus

23

En une seule requête : quels sont les 5 produits qui génèrent le plus de CA, avec leur part dans le CA global ?

💡 Utiliser une fenêtre analytique (`SUM() OVER()`) ou un CTE.

24

En une seule requête : quels sont les 5 pays qui génèrent le plus de CA (UK inclus), avec leur part dans le CA global ?

4.2 Comportement client

25

Parmi les clients identifiés (hors Unknown), quels sont les 5 clients avec le CA le plus élevé ? Et les 5 avec le plus de commandes ? Est-ce que les deux listes se recoupent ?

💡 Deux requêtes séparées suffisent.

26

Quel est le taux d'annulation global du segment Unknown, et comment se compare-t-il au taux d'annulation des clients identifiés ?

4.3 Vérification des hypothèses

27

Confirmer en SQL que le Royaume-Uni est le pays avec le plus de transactions et de commandes.

28

Confirmer en SQL que septembre, octobre et novembre sont les mois dépassant 1 million de livres de CA.

29

Calculer le taux d'annulation global de la boutique, puis le taux d'annulation pour les USA spécifiquement. Mettre les deux en regard.

💡 Cette question illustre pourquoi le taux global 'faible' peut masquer des anomalies locales.

Bonus — Pour aller plus loin

Écrire une requête unique avec plusieurs CTEs qui reproduit l'intégralité du tableau de synthèse :

produit | CA | nb_commandes | taux_annulation | rang_CA — pour les 20 premiers produits.